Autocorrelação Espacial

Curso de Econometria Espacial

Prof. Pedro Amaral

Cedeplar/UFMG

2º Semestre 2026

Aleatoriedade espacial

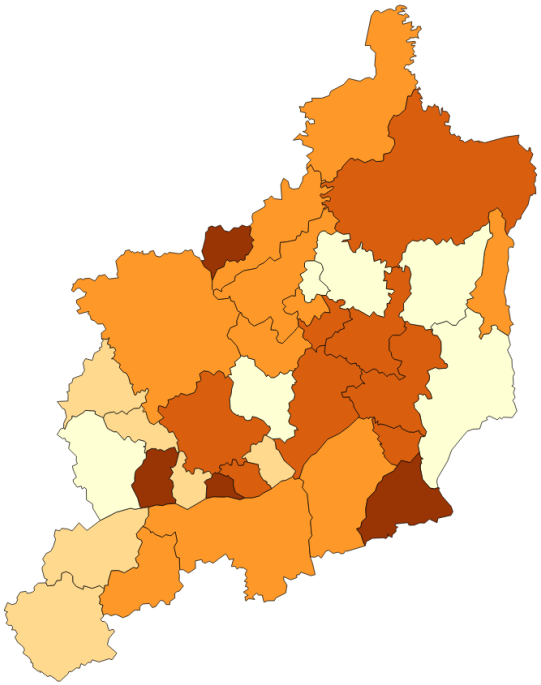
Hipótese nula: o espaço não importa

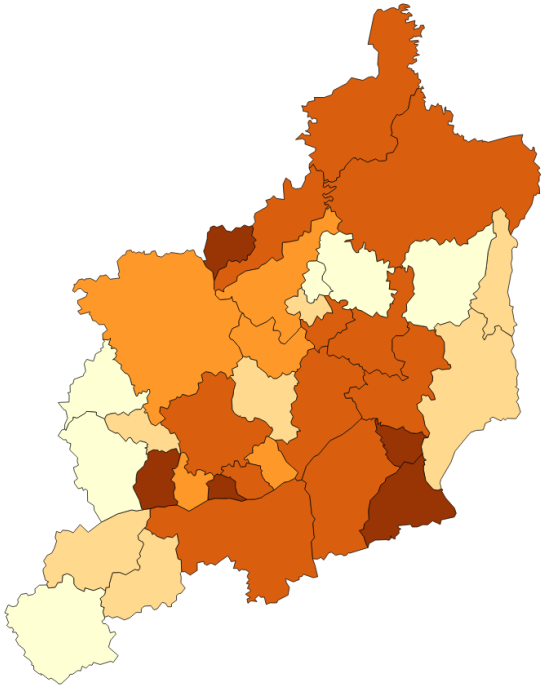
- Cada localidade é igualmente provável
- O valor observado em uma localidade **não** é correlacionado com o das demais

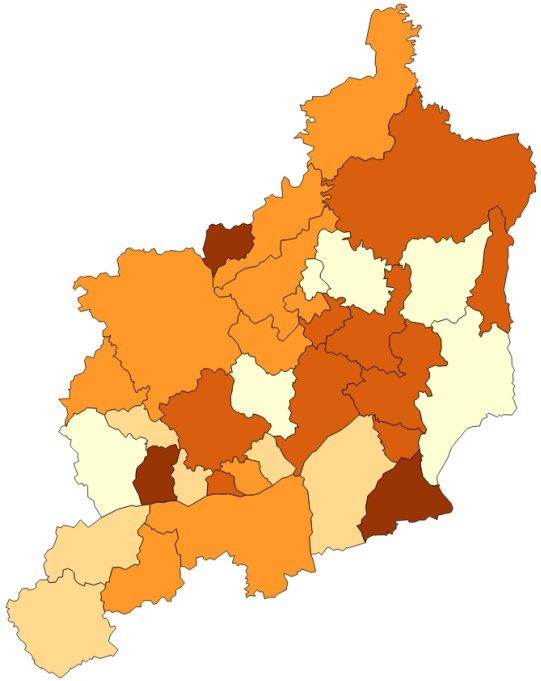
Autocorrelação espacial

Interseção entre **similaridade de valores** e **similaridade de localidade**.

Aleatoriedade espacial

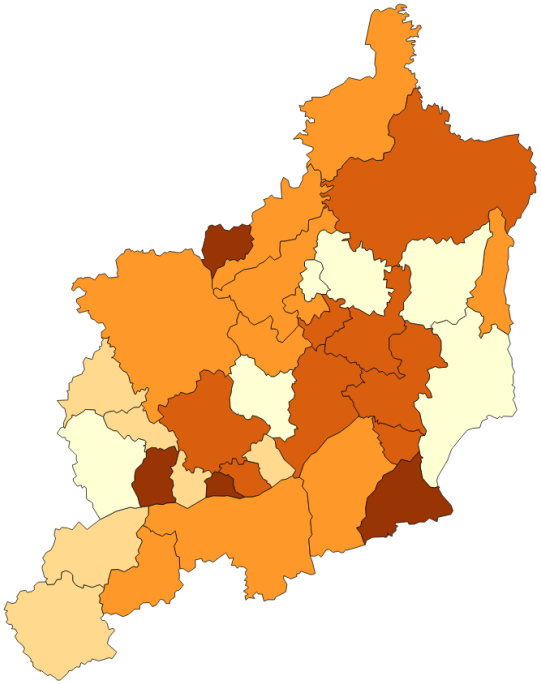




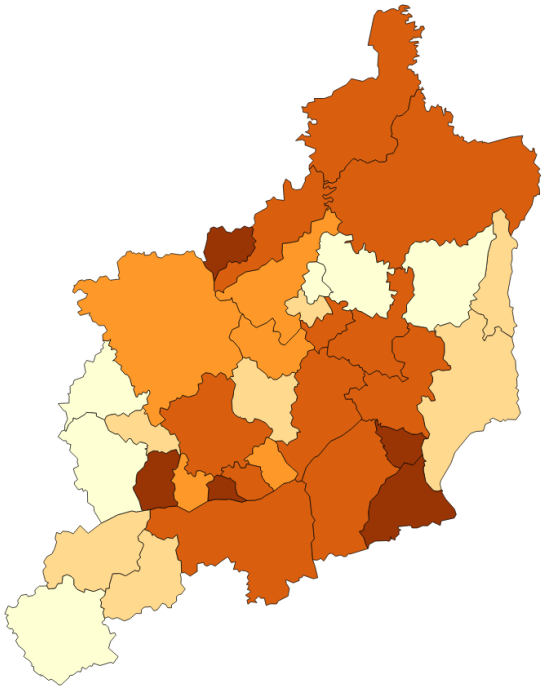


Como medir? $\rightarrow$ **testes de autocorrelação**

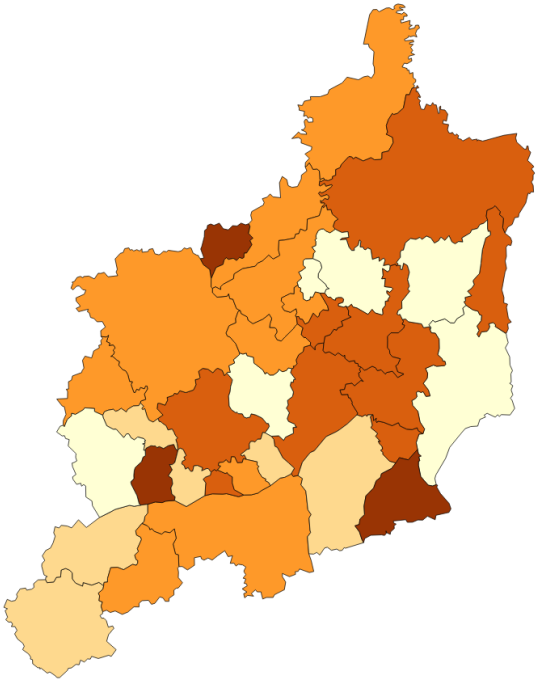
Aleatoriedade espacial



$I = 0{,}24$



$I = -0{,}02$

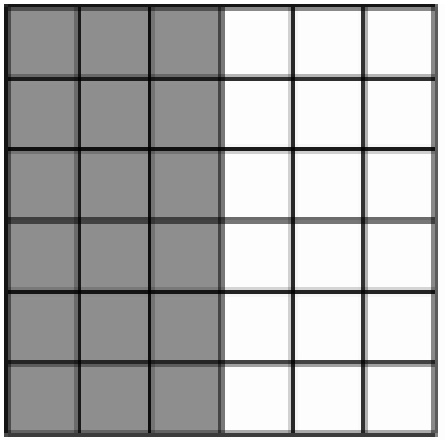


$I = -0{,}20$

Como medir? $\rightarrow$ **testes de autocorrelação**

Autocorrelação espacial positiva

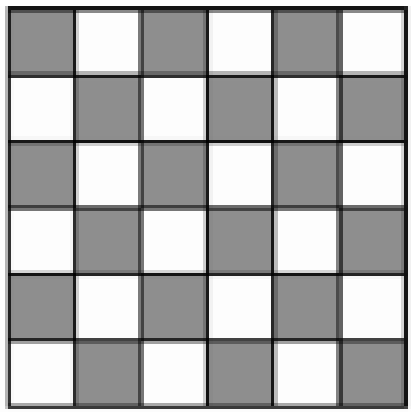
- Clusters ou **aglomerados**
- Valores **similares** se localizam próximos
- Vizinhos têm valores semelhantes
- Transbordamentos / *spillovers*?
  - **Não necessariamente**



Positive spatial autocorrelation

Autocorrelação espacial negativa

- Oposto de aglomerados
- Valores **diferentes** se localizam próximos
- Vizinhos discrepantes (Alto–Baixo, Baixo–Alto)
- Competição?
  - **Não necessariamente**



Causas da aglomeração

Contágio real

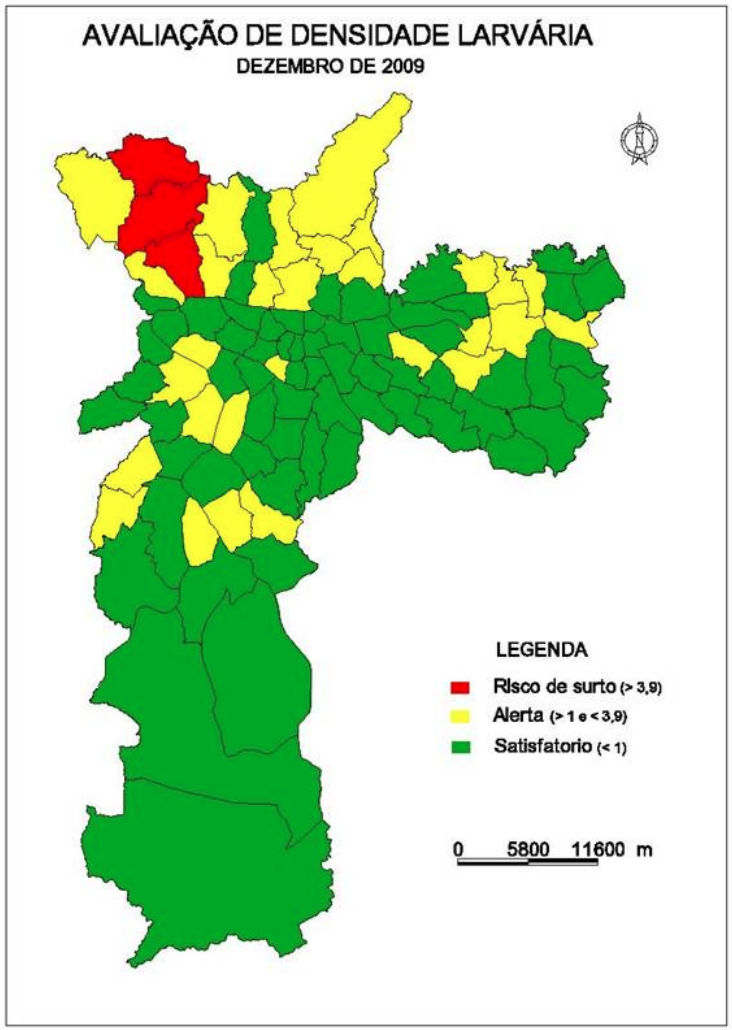
- Processo dinâmico
- Interação social

Contágio aparente

- Heterogeneidade espacial
- Exposição a um mesmo processo
- Interação **não** é necessária

Limitação

Em *cross-section* não é possível distinguir.
É necessária informação temporal.



Aglomeração vs. aglomerados

Aglomeração (*clustering*)

- Característica **global**
- Aleatoriedade incompatível com os dados *como um todo*
- Não indica localização
- Não distingue altos de baixos
- Ex.: *I* de Moran

Aglomerados (*clusters*)

- Característica **local**
- Localidades em que a aleatoriedade é incompatível
- É possível identificar aglomerados mesmo sem aglomeração global
- Ex.: *I* de Moran local

Autocorrelação global

Join Count

- Dados **binários** em polígonos
- $x_i = 1$ (preto) ou $x_i = 0$ (branco)
- Conta junções de valores iguais em localidades vizinhas

Exemplo

Existência de UTI adulto SUS por município: tem / não tem.

Join Count — similaridade e dissimilaridade

Similaridade (positiva)

- BB: 1s próximos de 1s
- WW: 0s próximos de 0s

Dissimilaridade (negativa)

- BW: 1s próximos de 0s

Junção	Contagem
1 com 1	$x_i\, x_j$
0 com 0	$(1 - x_i)(1 - x_j)$
1 com 0 ou 0 com 1	$(x_i - x_j)^2$

Join Count — estatísticas

Com W binária ($w_{ij} = 1$ se vizinhos):

$$BB = \frac{1}{2} \sum_i \sum_j w_{ij}\, x_i x_j$$

$$WW = \frac{1}{2} \sum_i \sum_j w_{ij}\, (1 - x_i)(1 - x_j)$$

$$BW = \frac{1}{2} \sum_i \sum_j w_{ij}\, (x_i - x_j)^2$$

$$BB + WW + BW = \frac{S_0}{2}$$

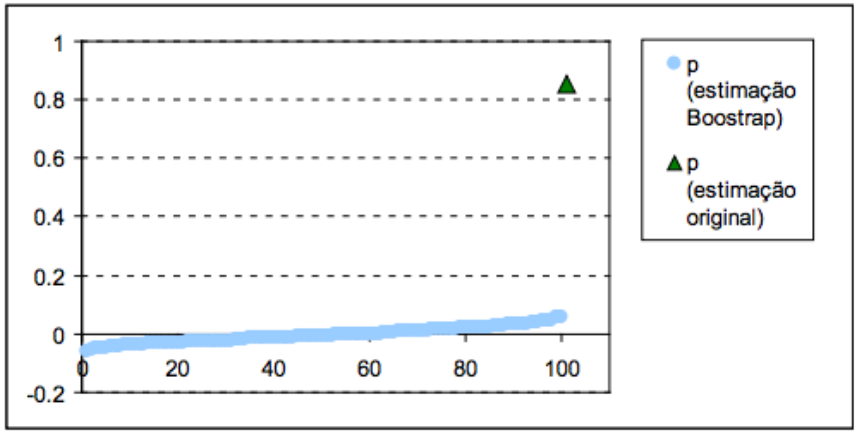


Hipóteses alternativas

Join Count testa aleatoriedade **contra BB, ou WW, ou BW** — separadamente.

Join Count — inferência

- Distribuição binomial (com ou sem reposição)
- **Permutação** / aleatorização
  - "Embaralha" os dados e recalcula a estatística
  - Compara o valor original com a distribuição empírica



Pseudo-significância

$$p = \frac{M+1}{N+1}$$

M = número de permutações tão extremas quanto o valor observado;
$N = 99, 499, 999, \ldots$

I de Moran

- Dados **contínuos** (pontos ou polígonos)
- $z_i = x_i - \bar{x}$: desvios em relação à média
- Similar, mas **não equivalente**, ao coeficiente de correlação
- Valores **dependem de** W

$$I = \frac{N}{S_0} \frac{\sum_i \sum_j w_{ij} z_i z_j}{\sum_i z_i^2}, \qquad S_0 = \sum_i \sum_j w_{ij}$$

Coeficiente de correlação de Pearson:

$$r = \frac{\sum_i (x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum_i (x_i - \bar{x})^2} \sqrt{\sum_i (y_i - \bar{y})^2}}$$

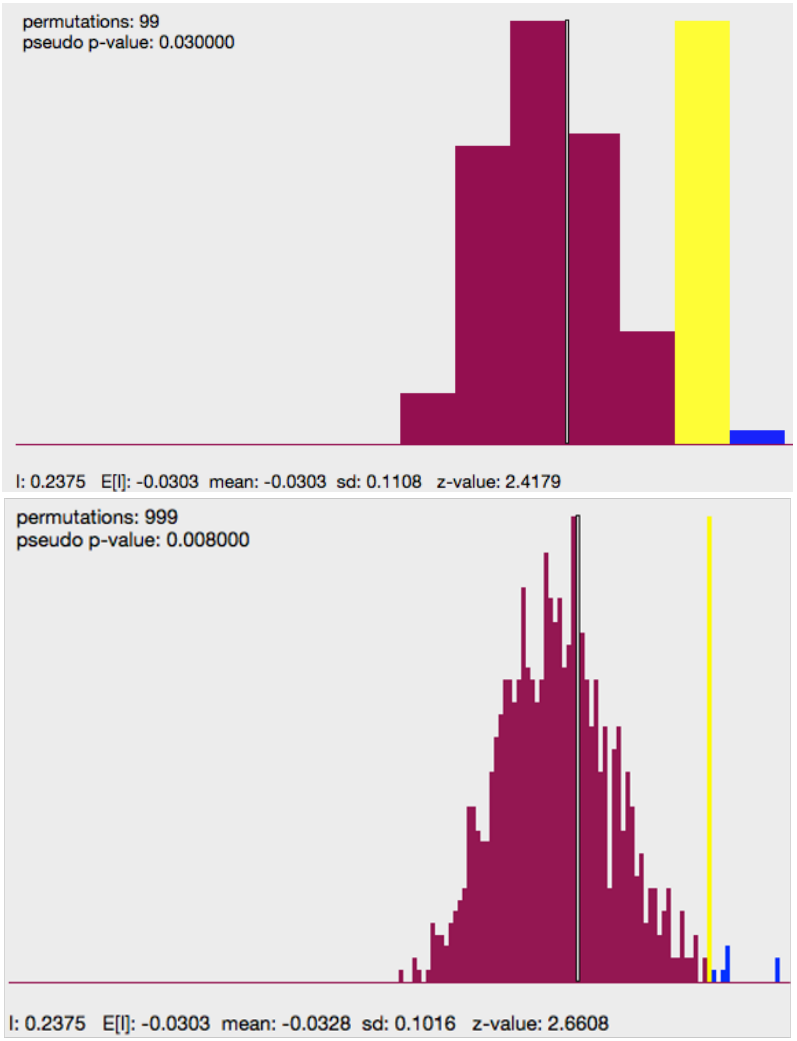
I de Moran — inferência

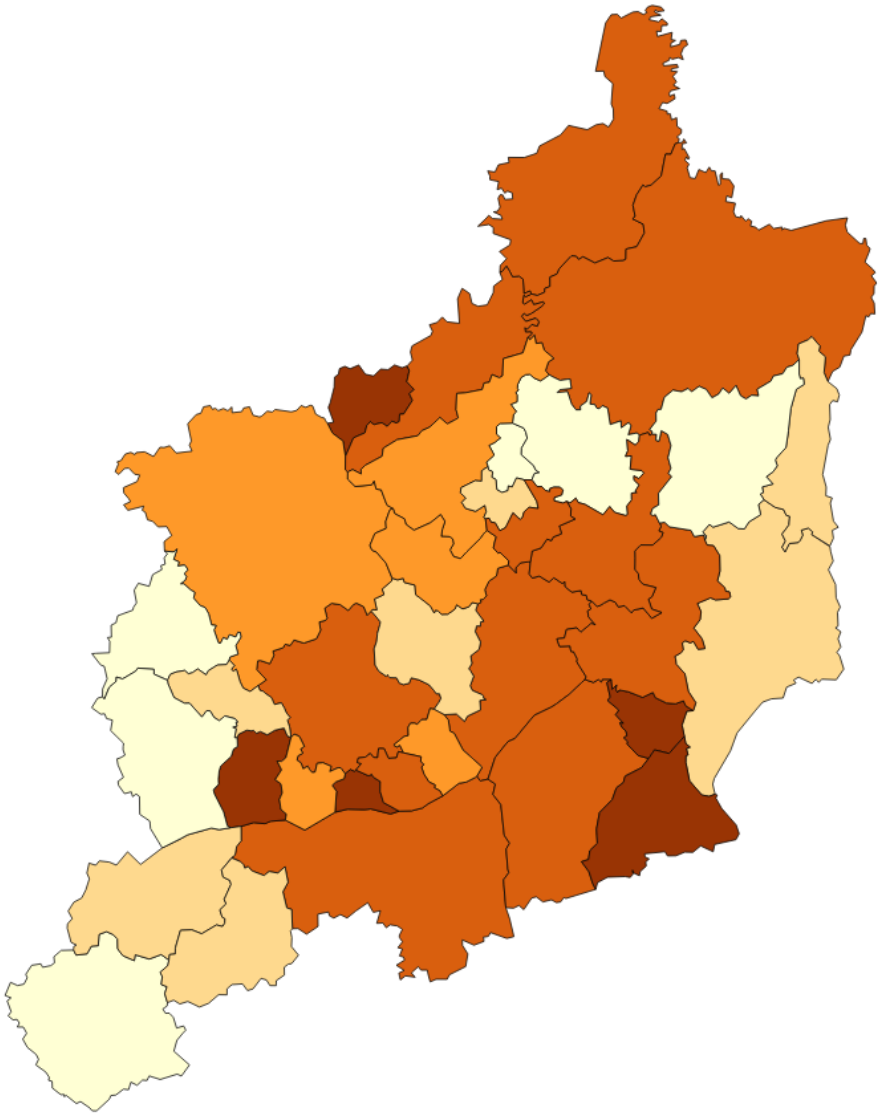
- **Analítica**: requer a distribuição exata de X e W
  - Aproximação normal (tamanho da amostra importa)
- **Permutação**: pseudo-significância

Cuidado com o p-valor

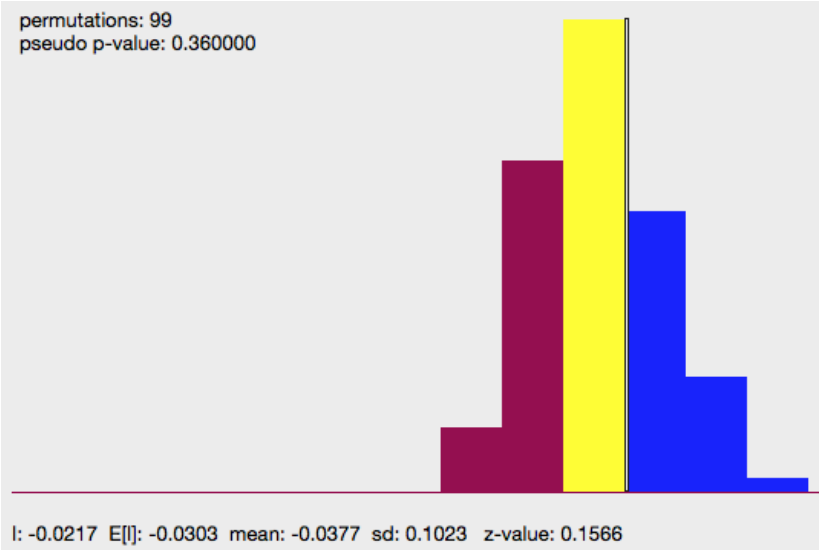
$p = 0{,}01$ **não** é necessariamente "menos significativo" que $p = 0{,}001$.
Depende de quantas permutações foram usadas.
Mais permutações $\rightarrow$ mais estabilidade, não mais evidência.

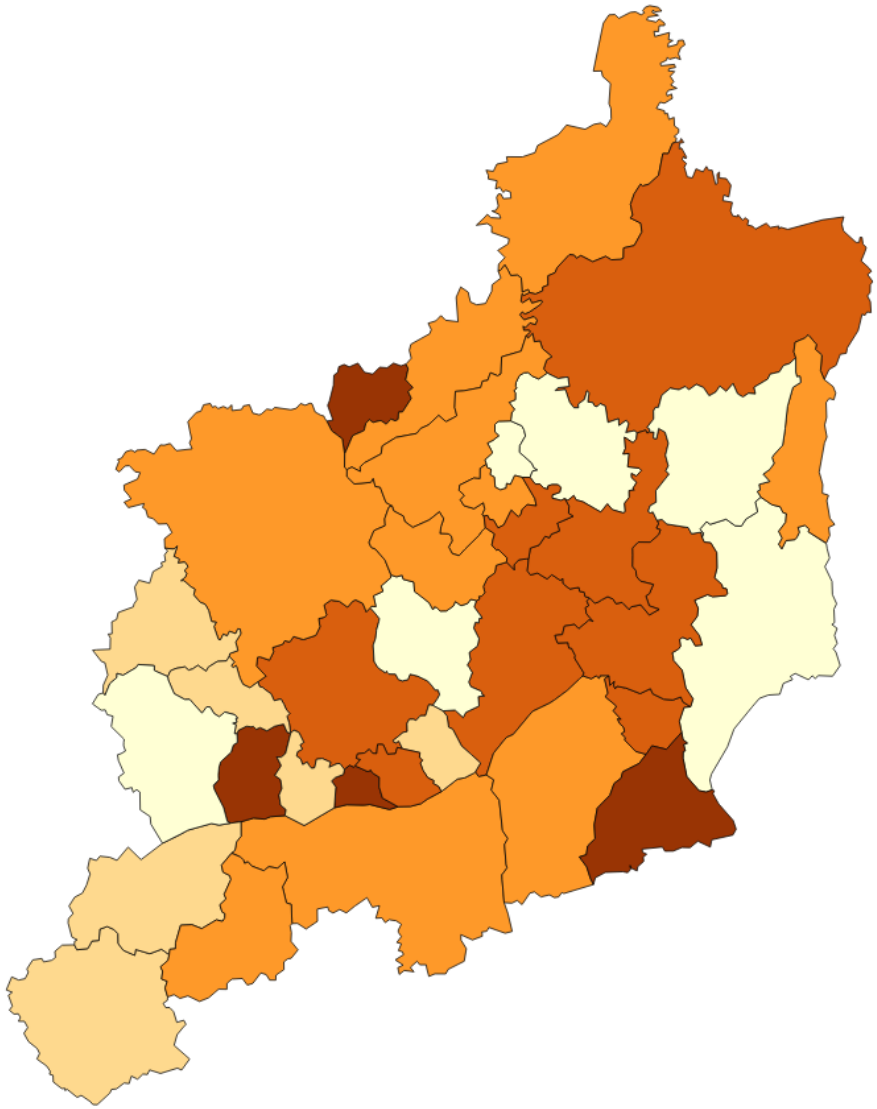
I de Moran


permutations: 99
pseudo p-value: 0.030000
I: 0.2375 E[I]: -0.0303 mean: -0.0303 sd: 0.1108 z-value: 2.4179
permutations: 999
pseudo p-value: 0.008000
I: 0.2375 E[I]: -0.0303 mean: -0.0328 sd: 0.1016 z-value: 2.6608



I de Moran


permutations: 99
pseudo p-value: 0.360000
I: -0.0217 E[I]: -0.0303 mean: -0.0377 sd: 0.1023 z-value: 0.1566
permutations: 999
pseudo p-value: 0.456000
I: -0.0217 E[I]: -0.0303 mean: -0.0305 sd: 0.1058 z-value: 0.0833



I de Moran — valores e padronização

- O valor de I **depende de** W
- Não é comparável entre mapas / matrizes diferentes
- Use o valor padronizado:

$$z_I = \frac{I - \mathrm{E}[I]}{\mathrm{DP}[I]}, \qquad \mathrm{E}[I] = -\frac{1}{N-1}$$

- $\mathrm{E}[I]$ **não** é zero

$$\mathrm{Var}[I] = \frac{N^2 S_1 - N S_2 + 3 S_0^2}{S_0^2 (N-1)(N+1)} - \left(\frac{1}{N-1}\right)^2$$

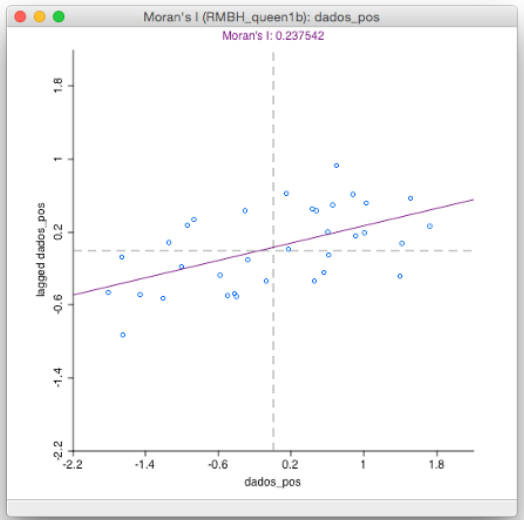
$$I \in \left[\frac{N\lambda_{\min}}{\sum_i \sum_j w_{ij}}, \frac{N\lambda_{\max}}{\sum_i \sum_j w_{ij}}\right]$$

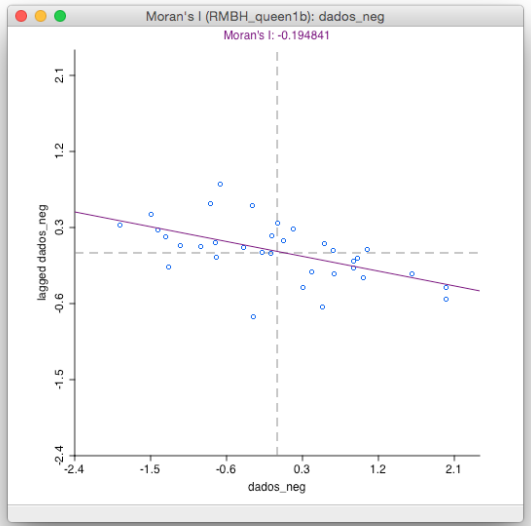
Estatísticas de W

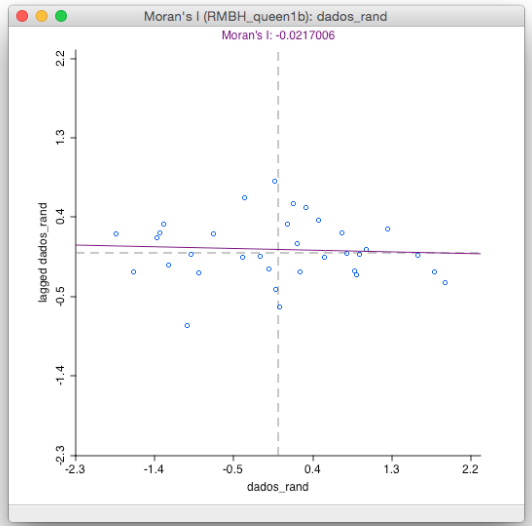
$$S_0 = \sum_i \sum_j w_{ij}, \quad S_1 = \tfrac{1}{2} \sum_i \sum_j (w_{ij} + w_{ji})^2, \quad S_2 = \sum_j \left(\sum_i w_{ij} + \sum_i w_{ji}\right)^2$$

I de Moran — interpretação

- Interpreta-se apenas **estatísticas significativas**
- Se $z_I > 0$: autocorrelação **positiva**
  - Não distingue altos-com-altos de baixos-com-baixos
- Se $z_I < 0$: autocorrelação **negativa**
- Se não significativo: não se rejeita aleatoriedade espacial







Outras estatísticas

- Estatística Γ (Gamma)
- c de Geary
- Estatística G de Getis-Ord

Getis-Ord

Não detecta autocorrelação negativa.
Identifica *hot spots* e *cold spots* (associação de valores altos ou baixos).

Autocorrelação local

LISA

LISA: *Local Indicators of Spatial Autocorrelation*

- Indicam autocorrelação significativa **para cada localidade**
- A soma das estatísticas locais é proporcional ao indicador global
- Ex.: *I* de Moran global é a **média** dos *I* locais
- Ferramenta de **análise exploratória**

I de Moran local

$$I_i = \frac{z_i}{m_2} \sum_j w_{ij} z_j, \qquad m_2 = \frac{1}{N} \sum_i z_i^2$$

- m_2 é constante para todas as localidades
- Se a variável está padronizada, $m_2 = 1$
- $\sum_i I_i = N \cdot I$
- $I = \sum_i I_i / N$

Implicação

O indicador global é a média dos indicadores locais.

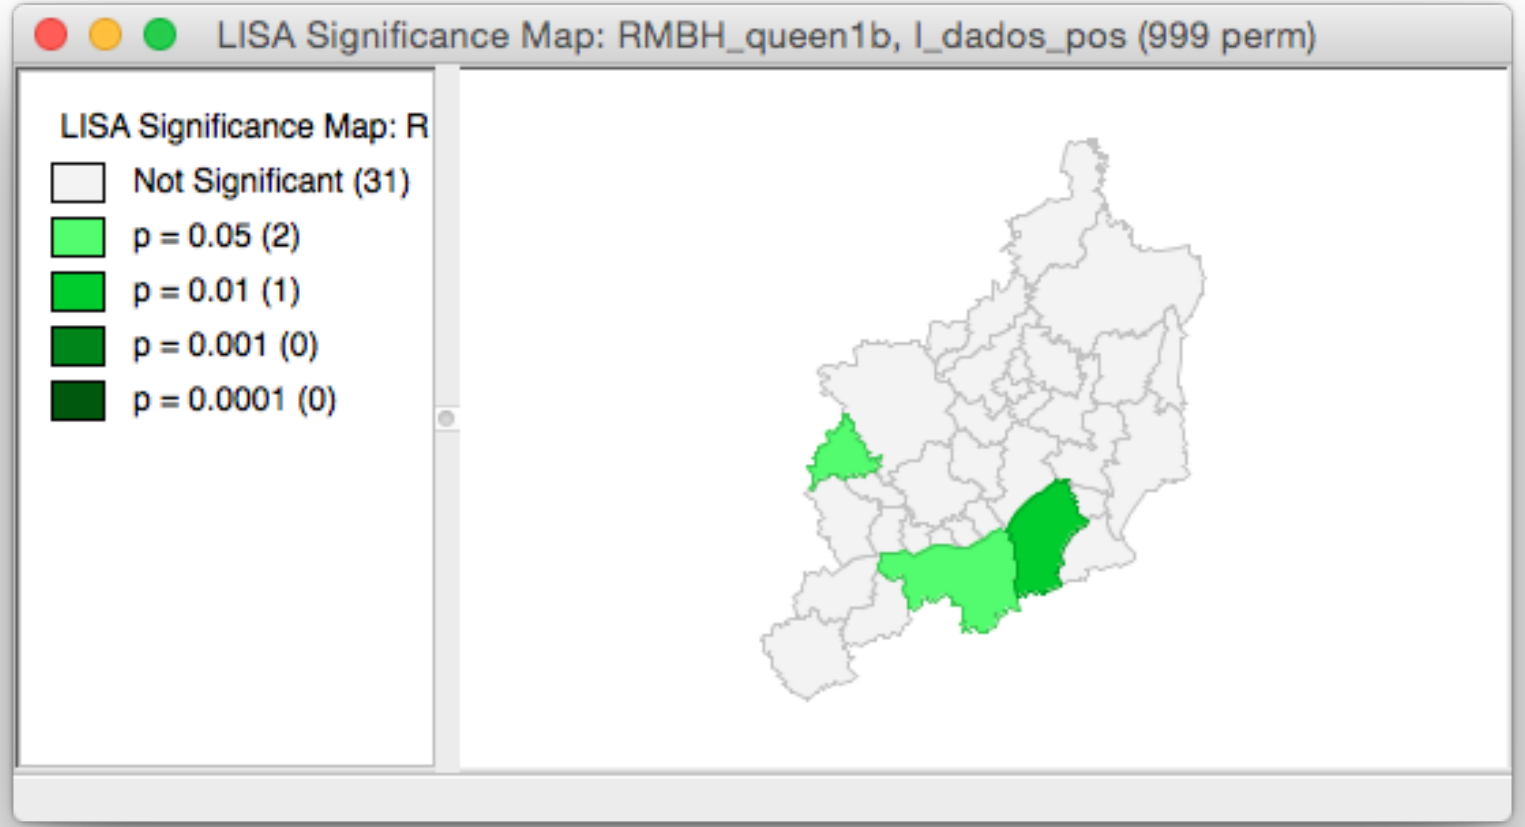
I de Moran local — inferência

- **Analítica**: aproximação normal — ruim em pequenas amostras
- **Computacional**: permutação **condicional**
  - K permutações **para cada** localidade ($K = 99, 499, 999, \ldots$)
  - Valor da localidade fica **fixo**
  - Imputam-se valores aleatórios aos vizinhos

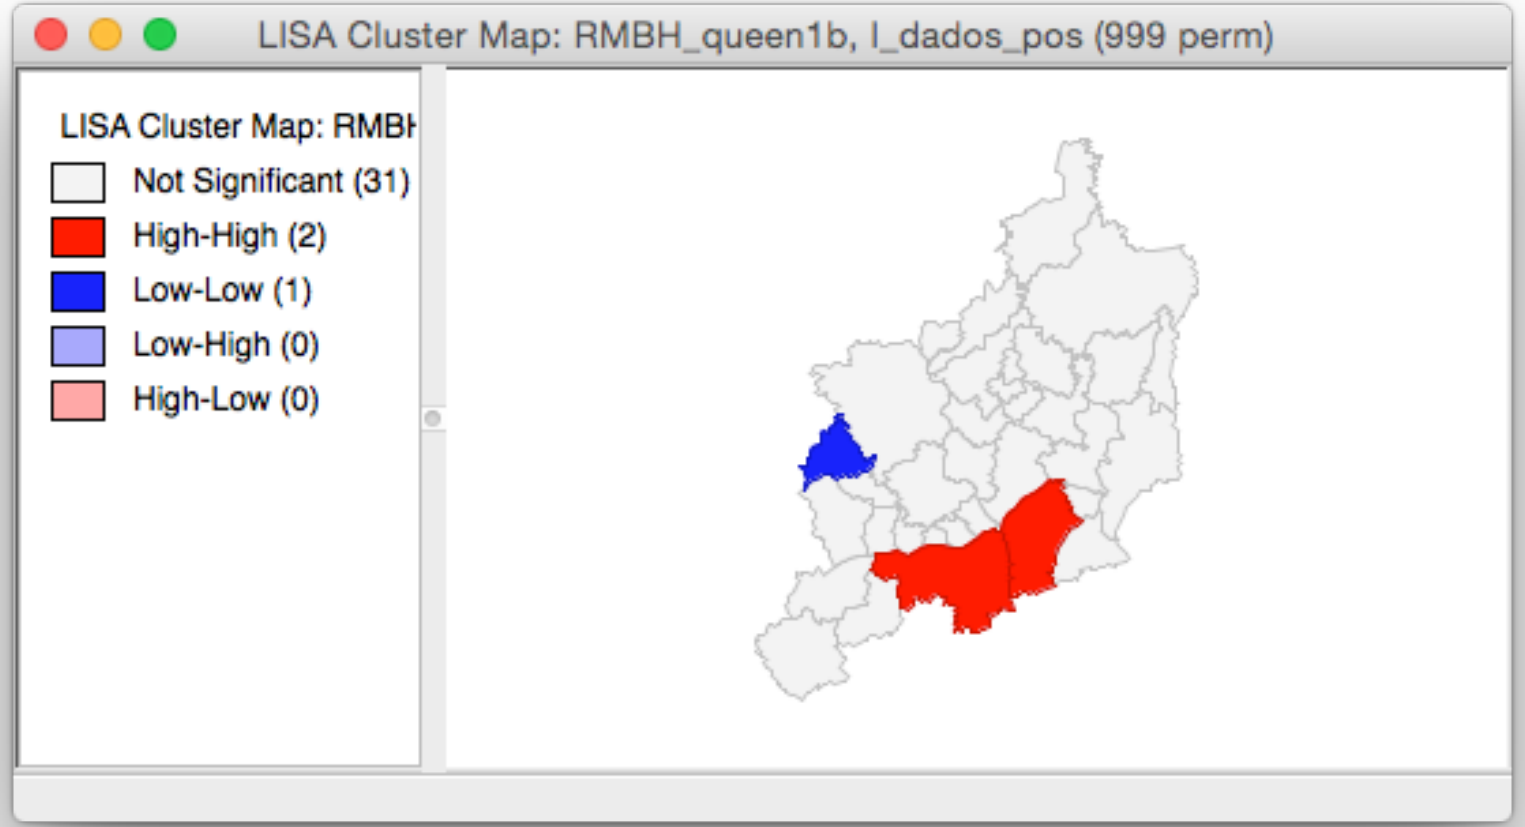
Cuidado

LISA faz N testes. É possível aplicar Bonferroni, FDR ou o filtro de Anselin (só reportar núcleos significativos *e* com vizinhos significativos).

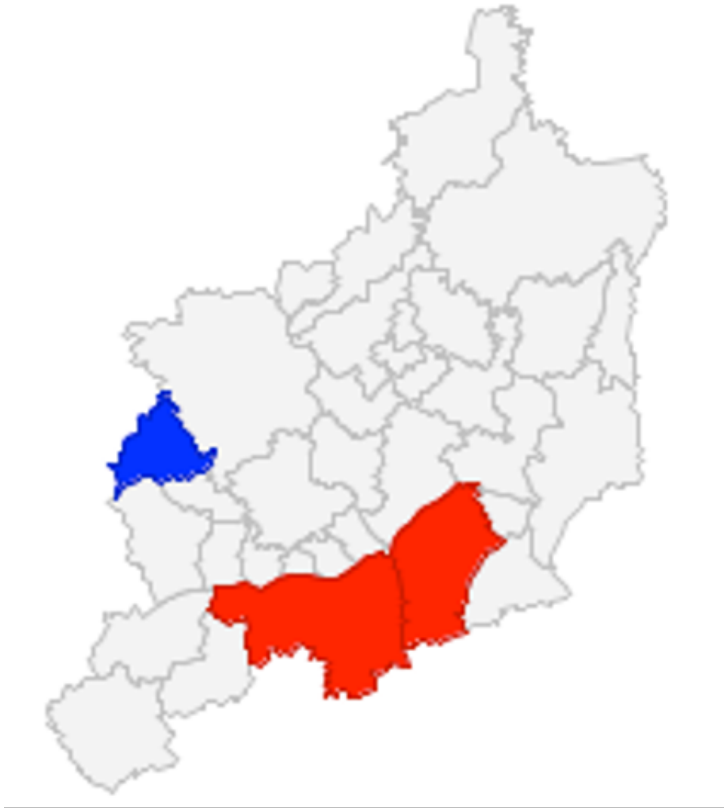
Mapa de significância



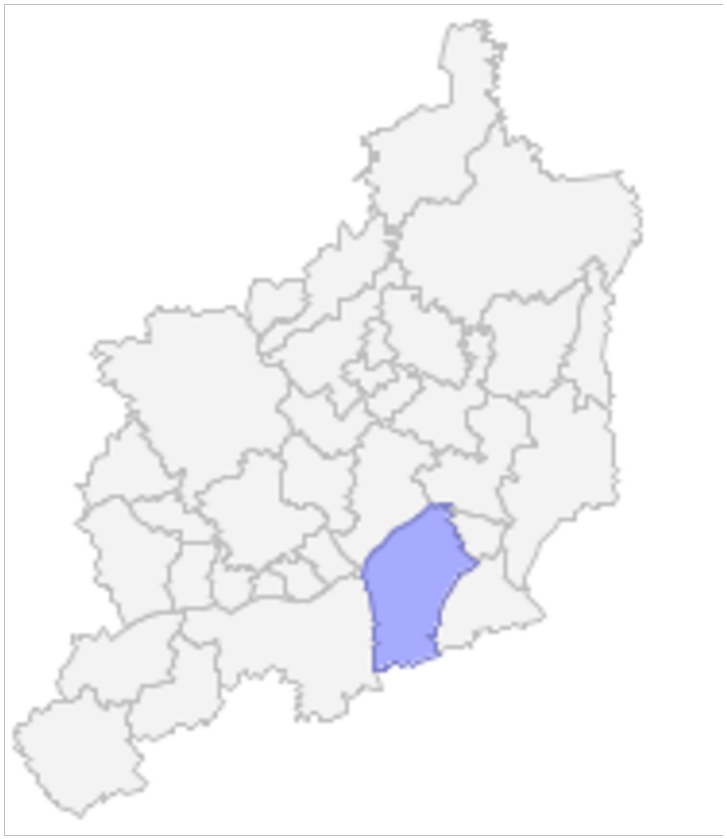
Mapa de aglomerados (*cluster map*)



I de Moran local — exemplo



$I = 0{,}24$ (aglomeração global)



$I = -0{,}02$ (não significativo)

É possível ter aglomerados locais mesmo sem aglomeração global.

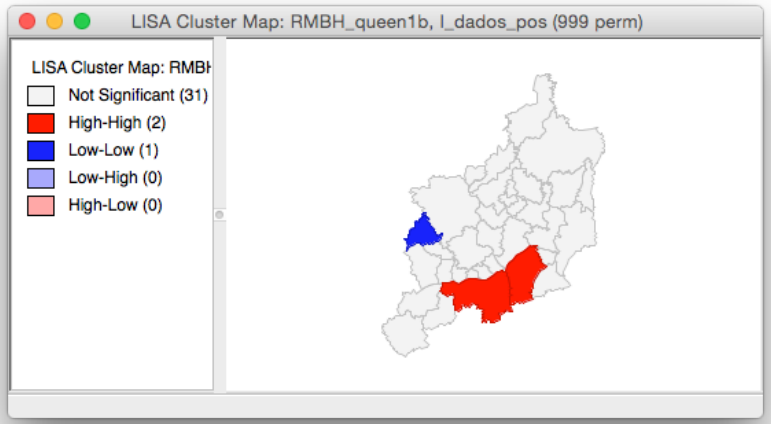
Outliers e núcleos

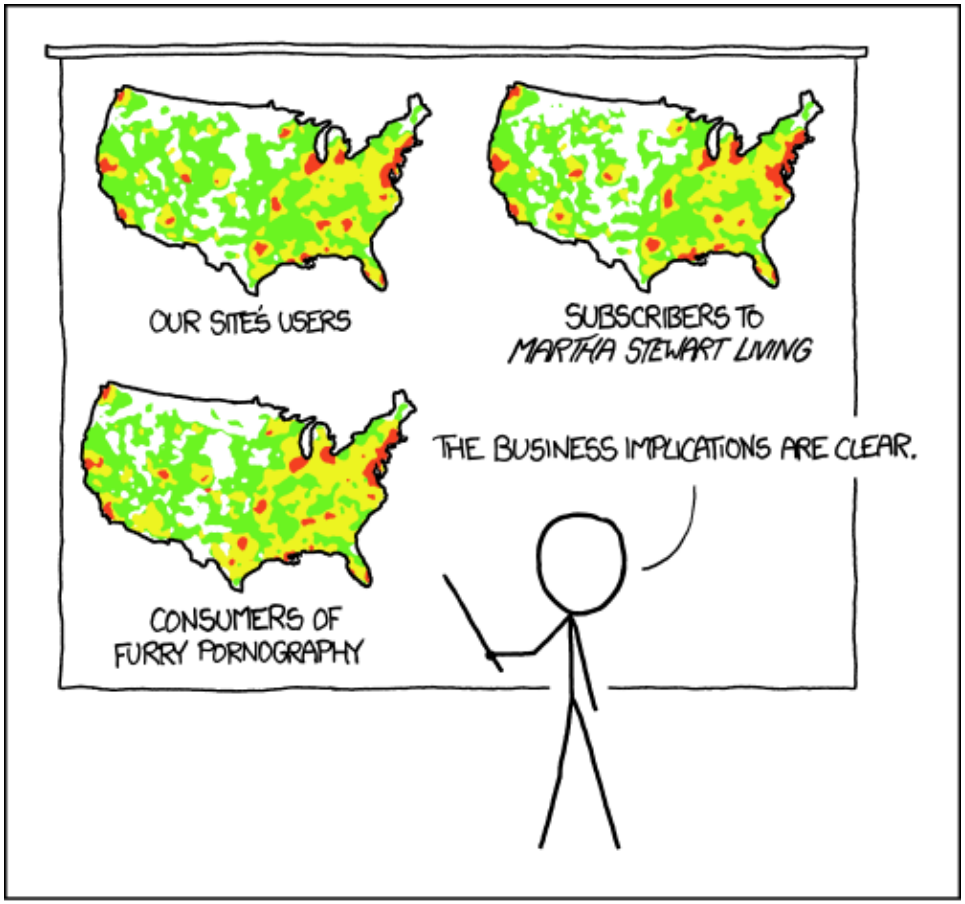
Outliers espaciais

- Autocorrelação **negativa**
- Localidades individuais (HL, LH)

Aglomerados espaciais

- Núcleo do aglomerado
- Autocorrelação **positiva** (HH, LL)





Fonte: xkcd #208

Próximos passos

- Hoje: testes globais e locais de autocorrelação
- Próxima aula: **testes de especificação**
  - Multiplicadores de Lagrange
  - SAR vs. SEM vs. SLX
  - Testes robustos