Painel espacial

Curso de Econometria Espacial

Prof. Pedro Amaral

Cedeplar/UFMG

2º Semestre 2026

Por que painel

- Maior número de observações: variabilidade, graus de liberdade e, em geral, eficiência
- Identificação de relações que o corte transversal não separa (heterogeneidade não observada invariante no tempo)
- Dimensão espacial $i = 1, \ldots, N$ e temporal $t = 1, \ldots, T$

Especificação-base

$$y_{it} = \mathbf{x}_{it}'\beta + \mu_i + \varepsilon_{it}, \qquad \varepsilon_{it} \text{ i.i.d.}$$

- μ_i: heterogeneidade individual não observada, constante no tempo
- β comum em i e em t
- **Pooled**: $\mu_i = 0$
- **Efeito fixo**: $\mathrm{Cov}(\mu_i, \mathbf{x}_{it}) \neq 0$
- **Efeito aleatório**: $\mathrm{Cov}(\mu_i, \mathbf{x}_{it}) = 0$

O estimador de efeito fixo coincide com o MQO que inclui uma dummy por unidade (LSDV - least squares dummy variables; Baltagi, 2001).

Parâmetros variáveis em t — SUR ($N > T$)

$$\mathbf{y}_t = \mathbf{X}_t \beta_t + \varepsilon_t, \qquad t = 1, \ldots, T$$

$$\mathrm{E}(\varepsilon_t \varepsilon_s') = \sigma_{ts} \mathbf{I}_N$$

- β fixo no espaço e distinto por período
- Uma equação por t, com covariância do erro **entre períodos**
- Requer $N > T$ para $\Sigma = (\sigma_{ts})$ ser estimável

Parâmetros variáveis em i — SUR ($T > N$)

$$\mathbf{y}_i = \mathbf{X}_i \boldsymbol{\beta}_i + \boldsymbol{\varepsilon}_i, \qquad i = 1, \ldots, N$$

$$\mathrm{E}(\boldsymbol{\varepsilon}_i \boldsymbol{\varepsilon}_j') = \sigma_{ij} \mathbf{I}_T$$

- $\boldsymbol{\beta}$ fixo no tempo e distinto por unidade
- Uma equação por i, com covariância do erro **entre unidades**
- Requer $T > N$

Extensões: coeficientes aleatórios (Swamy); painel dinâmico ($y_{i,t-1}$), etc.

Efeitos fixos

FE — erro espacial

$$\mathbf{y}_t = \mathbf{X}_t\beta + \boldsymbol{\mu} + \mathbf{u}_t, \qquad \mathbf{u}_t = \lambda\mathbf{W}\mathbf{u}_t + \boldsymbol{\varepsilon}_t$$

Após desvios em relação à média temporal da unidade ($\mathbf{y}_t^* = \mathbf{y}_t - \bar{\mathbf{y}}$, idem para X):

$$\ell(\beta, \lambda, \sigma^2) = -\frac{NT}{2}\ln(2\pi\sigma^2) + T\ln|\mathbf{I}_N - \lambda\mathbf{W}| - \frac{1}{2\sigma^2}\sum_{t=1}^{T}\mathbf{e}_t'\mathbf{e}_t$$

$$\mathbf{e}_t = (\mathbf{I}_N - \lambda\mathbf{W})\mathbf{y}_t^* - \mathbf{X}_t^*\beta$$

Elhorst (2003, 2014). $T\ln|\mathbf{I}_N - \lambda\mathbf{W}|$ é o jacobiano do corte, repetido em cada período. W é invariante em t.

FE — lag espacial

$$\mathbf{y}_t = \rho \mathbf{W}\mathbf{y}_t + \mathbf{X}_t\beta + \boldsymbol{\mu} + \boldsymbol{\varepsilon}_t$$

Após a transformação *within* ($\mathbf{y}_t^* = \mathbf{y}_t - \bar{\mathbf{y}}$, analogamente para $\mathbf{X}_t$):

$$\ell(\beta, \rho, \sigma^2) = -\frac{NT}{2}\ln(2\pi\sigma^2) + T\ln|\mathbf{I}_N - \rho\mathbf{W}| - \frac{1}{2\sigma^2}\sum_{t=1}^{T}\mathbf{e}_t'\mathbf{e}_t$$

$$\mathbf{e}_t = (\mathbf{I}_N - \rho\mathbf{W})\mathbf{y}_t^* - \mathbf{X}_t^*\beta$$

- $T\ln|\mathbf{I}_N - \rho\mathbf{W}|$ é o jacobiano do cross-section, repetido em cada período
- β não coincide com $\partial\mathbf{y}/\partial\mathbf{x}_k'$; os impactos seguem $(\mathbf{I}_N - \rho\mathbf{W})^{-1}\beta_k$, com W invariante em t

Parâmetro incidental

- Cada μ_i dispõe de apenas T observações
- Com T fixo e $N \to \infty$, $\hat{\mu}_i$ não é consistente (problema do parâmetro incidental; Neyman e Scott, 1948; Anselin, 2001)
- As propriedades assintóticas dos modelos espaciais fundamentam-se em $N \to \infty$; o problema é, portanto, mais restritivo do que no painel não espacial

Estratégia

Se o objeto de interesse é (β, ρ) ou (β, λ), e não $\boldsymbol{\mu}$, estima-se o modelo na transformação *within* (Elhorst, 2003). Lee e Yu (2010) propõem uma transformação adicional que elimina o viés de ordem $O(T^{-1})$ residual.

Verossimilhança após a transformação *within*

1. No empilhamento por período, $\mathbf{y} = (\mathbf{y}_1', \ldots, \mathbf{y}_T')'$, o *within* individual é $Q = (I_T - \iota_T \iota_T'/T) \otimes I_N$. No empilhamento clássico (por unidade) é $Q = I_N \otimes (I_T - \iota_T \iota_T'/T)$. Não se usa $I_T \otimes (I_N - \iota_N \iota_N'/N)$ (isso remove a média espacial de cada t)
2. $\mathrm{Var}(\mathbf{u}^*) = \sigma^2 Q \neq \sigma^2 \mathbf{I}_{NT}$. A verossimilhança em Elhorst (2003, p. 250) trata os resíduos transformados como esféricos

Lee e Yu (2010) corrigem a verossimilhança e o viés associado.

Em N grande, o jacobiano $|\mathbf{I}_N - \rho \mathbf{W}|$ (autovalores de W) permanece o gargalo computacional.

Efeitos aleatórios

Efeitos aleatórios

$$y_{it} = \mathbf{x}_{it}'\beta + \mu_i + u_{it}, \qquad \mathrm{Cov}(\mu_i, \mathbf{x}_{it}) = 0$$

Elhorst (2003, 2014):

$$\phi = \frac{\sigma_\varepsilon^2}{T\sigma_\mu^2 + \sigma_\varepsilon^2} \in (0, 1]$$

A transformação GLS é

$$y_{it}(\phi) = y_{it} - \left(1 - \sqrt{\phi}\right) \bar{y}_i$$

(idem para $\mathbf{x}_{it}$).

- $\phi \to 0$: $y_{it}(\phi) = y_{it} - \bar{y}_i$ (*within* / FE)
- $\phi = 1$: $y_{it}(\phi) = y_{it}$ (pooled)

RE — verossimilhança

Erro espacial ($u_{it} = \lambda \sum_j w_{ij} u_{jt} + \varepsilon_{it}$):

$$\ell = -\frac{NT}{2} \ln(2\pi\sigma_\varepsilon^2) + T \ln |\mathbf{I}_N - \lambda \mathbf{W}| - \frac{N}{2} \ln\left(T\sigma_\mu^2 + \sigma_\varepsilon^2\right) - \frac{1}{2\sigma_\varepsilon^2} \tilde{\mathbf{e}}'\tilde{\mathbf{e}}$$

em que $\tilde{\mathbf{e}}$ é o resíduo após o GLS do efeito aleatório (ponderação *between*/*within* por ϕ). Lag espacial: substitui-se $|\mathbf{I}_N - \lambda \mathbf{W}|$ por $|\mathbf{I}_N - \rho \mathbf{W}|$ e

$$\tilde{\mathbf{e}} = (\mathbf{I}_N - \rho \mathbf{W})\tilde{\mathbf{y}} - \tilde{\mathbf{X}}\beta.$$

KKP vs. Baltagi / Anselin

Componente de erro do RE:

$$u_{it} = \mu_i + v_{it}$$

μ_i: heterogeneidade permanente (invariante em t). v_{it}: inovação idiosincrática.

	Baltagi et al. (2003)	KKP (2007)
v_{it}	$v_t = \lambda W v_t + \varepsilon_t$	$(I_N - \rho W)v_t = \varepsilon_t$
μ_i	$\mathrm{E}(\mu_i \mu_j) = 0,\ i \neq j$	$(I_N - \rho W)\mu = \eta$
Parâmetro espacial	um (λ), só em v	um ρ em μ **e** em v
Estimação	MV / FGLS	GMM

Anselin (1988) é o SEM de cross-section. Baltagi et al. aplicam-no a cada t e mantêm μ_i espacialmente não correlacionado. KKP permitem a correlação espacial no termo regional invariante.

KKP — estrutura

$$\mathbf{u} = (\boldsymbol{\iota}_T \otimes \mathbf{I}_N)\boldsymbol{\mu} + \boldsymbol{\varepsilon}$$

Tanto $\boldsymbol{\mu}$ quanto $\boldsymbol{\varepsilon}$ passam pelo mesmo filtro $(\mathbf{I}_N - \rho\mathbf{W})^{-1}$. Hipóteses usuais:

- $w_{ii} = 0$; $|\rho| < 1$; $\mathbf{I}_N - \rho\mathbf{W}$ invertível
- W_N esparsa

Resultado: autocorrelação no espaço **e** persistência no tempo (se $\sigma^2_\mu > 0$).

KKP — momentos

$Q_{0,N}$ remove a média temporal da unidade; $Q_{1,N}$ é o projetor sobre essa média; $Q_0 + Q_1 = I$.

$$\sigma_1^2 = \sigma_v^2 + T\sigma_\mu^2$$

Quatro momentos em ρ, σ_v^2 e σ_1^2 (traços envolvendo $W\hat{\mathbf{u}}$).

KKP — algoritmo

1. MQO $\rightarrow \hat{\mathbf{u}}$
2. Otimização não linear nas três primeiras equações de momento: $\hat{\rho}$, $\hat{\sigma}_v^2$
3. Quarta equação: $\hat{\sigma}_1^2$
4. Atualização com o sistema completo de momentos
5. MQO nos dados filtrados e ponderados (FGLS factível)

Inferência sobre ρ: bootstrap.

Filtro e ponderador

Filtro espacial:

$$(\mathbf{I}_N - \hat{\rho}\mathbf{W})\mathbf{y}_t$$

Ponderador: combinação de Q_0 e Q_1 com $\hat{\sigma}_v^2$ e $\hat{\sigma}_1^2$ (GLS do componente de erro).
Atrativo computacional: N grande, T pequeno — evita o jacobiano da MV.

Testes espaciais

FE ou RE?

Lee e Yu (2012) estendem o teste de Hausman ao painel espacial.

$$H_0 : \ \mathrm{Cov}(\mu_i, \mathbf{x}_{it}) = 0 \qquad \text{(RE consistente e eficiente sob } H_0\text{)}$$

- Rejeição $\Rightarrow$ RE é inconsistente; estima-se o FE na transformação *within* (com a correção de Lee e Yu, 2010, se T for pequeno)
- Não rejeição $\Rightarrow$ RE é admissível

Amostra finita de unidades

Se o conjunto de i esgota a população (municípios de um estado, UF), μ_i não é extraído de uma superpopulação. Nesse caso o FE é a parametrização natural, independentemente do Hausman, se hipóteses usuais válidas.

Lag ou erro no painel

- Anselin, Le Gallo e Jayet (2006): estatísticas LM de lag e de erro para painel, análogas às de cross-section
- Elhorst (2010): formas robustas à presença da alternativa não testada

A regra de decisão segue a rota clássica: as versões robustas só se interpretam se **ambos** os LM clássicos rejeitam H_0.

SUR espacial

SUR — β varia em t ($N > T$)

Uma equação por período; β_t distinto. Com erro espacial em cada corte:

$$\mathbf{u}_t = \lambda_t \mathbf{W}\mathbf{u}_t + \boldsymbol{\varepsilon}_t, \qquad \mathrm{E}(\boldsymbol{\varepsilon}_t \boldsymbol{\varepsilon}_s') = \sigma_{ts}\mathbf{I}_N$$

$$\begin{bmatrix} \mathbf{y}_1 \\ \mathbf{y}_2 \\ \vdots \\ \mathbf{y}_T \end{bmatrix} = \begin{bmatrix} \mathbf{X}_1 & \mathbf{0} & \cdots & \mathbf{0} \\ \mathbf{0} & \mathbf{X}_2 & \cdots & \mathbf{0} \\ \vdots & \vdots & \ddots & \vdots \\ \mathbf{0} & \mathbf{0} & \cdots & \mathbf{X}_T \end{bmatrix} \begin{bmatrix} \beta_1 \\ \beta_2 \\ \vdots \\ \beta_T \end{bmatrix} + \begin{bmatrix} \mathbf{u}_1 \\ \mathbf{u}_2 \\ \vdots \\ \mathbf{u}_T \end{bmatrix}$$

SUR-erro — verossimilhança

$$\ell = -\frac{NT}{2}\ln(2\pi) - \frac{N}{2}\ln|\Sigma| + \sum_{t=1}^{T}\ln|\mathbf{I}_N - \lambda_t\mathbf{W}| - \tfrac{1}{2}\tilde{\mathbf{e}}'(\Sigma^{-1}\otimes\mathbf{I}_N)\tilde{\mathbf{e}}$$

- $\Lambda = \mathrm{diag}(\lambda_1, \ldots, \lambda_T)$
- $\Sigma = (\sigma_{ts})_{T\times T}$

SUR-lag

$$\mathbf{y}_t = \rho_t \mathbf{W}\mathbf{y}_t + \mathbf{X}_t \boldsymbol{\beta}_t + \boldsymbol{\varepsilon}_t$$

A verossimilhança substitui $|\mathbf{I}_N - \lambda_t \mathbf{W}|$ por $|\mathbf{I}_N - \rho_t \mathbf{W}|$ e redefine o resíduo filtrado. Alternativa à MV: **MQ3E**

1. MQ2E equação a equação (instrumenta $\mathbf{W}\mathbf{y}_t$)
2. Resíduos $\rightarrow \hat{\Sigma}$
3. Terceiro estágio com $\hat{\Sigma}$

SUR — β varia em i ($T > N$)

Simétrico: uma equação por unidade espacial, correlação do erro **entre** i, e a dimensão temporal desempenha o papel que N tinha no caso anterior. Na prática regional brasileira, $N > T$ é o caso típico (municípios $\times$ poucos anos) — o SUR relevante é o primeiro.

Mapa da aula

	Quando usar	Estimador
FE + SAR/SEM	μ_i correlaciona com X	MV em desvios
RE + SAR/SEM	μ_i não correlaciona com X	MV
KKP	μ e v espaciais; N grande, T pequeno	GMM
SUR-t	β_t distinto, $N > T$	MV ou MQ3E

Referências

- Anselin, L. (1988). *Spatial Econometrics: Methods and Models*. Kluwer.
- Anselin, L. (2001). Spatial econometrics. In Baltagi (ed.), *A Companion to Theoretical Econometrics*.
- Anselin, L., Le Gallo, J. e Jayet, H. (2006). Spatial panel econometrics. In Mátyás e Sevestre (eds.).
- Baltagi, B. H. (2001). *Econometric Analysis of Panel Data*. Wiley.
- Baltagi, B. H. e Li, D. (2004). Testing for linear and log-linear models against Box–Cox alternatives with spatial lag dependence. In Anselin, Florax e Rey (eds.).
- Elhorst, J. P. (2003). Specification and estimation of spatial panel data models. *IRSR*.
- Elhorst, J. P. (2010). Spatial panel data models. In Fischer e Getis (eds.).
- Elhorst, J. P. (2014). *Spatial Econometrics: From Cross-Sectional Data to Spatial Panels*. Springer.
- Kapoor, M., Kelejian, H. e Prucha, I. (2007). Panel data models with spatially correlated error components. *Journal of Econometrics*.
- Lee, L.-F. e Yu, J. (2010). Estimation of spatial autoregressive panel data models with fixed effects. *Journal of Econometrics*.
- Lee, L.-F. e Yu, J. (2012). Spatial panels: random components versus fixed effects. *IER*.