Inferência Causal para Dados Espaciais

Curso de Econometria Espacial

Prof. Pedro Amaral

Cedeplar/UFMG

2º Semestre 2026

Roteiro da Apresentação

1. Introdução e o Problema Fundamental
2. Propensity Score Matching
3. Regressão com Descontinuidade (RDD)
4. Diferenças-em-Diferenças (Diff-in-Diff)
5. Método do Controle Sintético (SCM)
6. References

O Problema Fundamental da Inferência Causal

Modelo Causal de Rubin (RCM)

O objetivo é estimar o efeito causal de um tratamento (D) sobre um resultado (Y). Para cada unidade i, existem dois **resultados potenciais**:

- $Y_i(1)$: O resultado se a unidade i recebe o tratamento ($D_i = 1$).
- $Y_i(0)$: O resultado se a unidade i **não** recebe o tratamento ($D_i = 0$).

O resultado que observamos é dado por:

$$Y_i = D_i Y_i(1) + (1 - D_i) Y_i(0)$$

O **problema fundamental** é que, para cada unidade, só podemos observar um dos resultados potenciais.

O Problema Fundamental da Inferência Causal

Estimandos de Interesse

Como não podemos observar o efeito individual $Y_i(1) - Y_i(0)$, focamos em médias populacionais:

- **ATE (Average Treatment Effect):** $\tau_{ATE} = E[Y(1) - Y(0)]$
- **ATT (Average Treatment Effect on the Treated):** $\tau_{ATT} = E[Y(1) - Y(0)|D = 1]$

A Pedra Angular: Pressuposto SUTVA

Para que os estimandos como ATE e ATT sejam bem definidos e identificáveis, uma hipótese crucial é a **Stable Unit Treatment Value Assumption (SUTVA)**.

A SUTVA possui dois componentes principais:

1. **Ausência de Variações Ocultas do Tratamento:**
   - Todas as unidades que recebem um determinado nível de tratamento recebem exatamente a mesma "versão"desse tratamento.
2. **Ausência de Interferência (No Interference):**
   - O resultado potencial de uma unidade i depende **apenas** do seu próprio status de tratamento, e não do status de tratamento de qualquer outra unidade j.
   - Formalmente: $Y_i(D_1, D_2, \ldots, D_N) = Y_i(D_i)$.

Problema

A **dependência espacial** pode violar diretamente a cláusula de **ausência de interferência**.

A Violação do SUTVA por Efeitos Espaciais

Em contextos espaciais, o pressuposto de não interferência é frequentemente irrealista.

Dependência Espacial:

- Interações entre unidades vizinhas (e.g., competição, cooperação, difusão).
- Causa efeitos de *spillover* (transbordamento).

Heterogeneidade Espacial:

- A resposta ao tratamento pode variar com a localização.

Exemplo: Intervenção de Trânsito

Uma intervenção de trânsito (tratamento) em um bairro pode atrair veículos de bairros vizinhos (controles), afetando a taxa de acidentes nestes.

A Violação do SUTVA por Efeitos Espaciais

Formalmente, a SUTVA pode ser violada em casos de interferência:

- Sob SUTVA, a independência é assumida: $(Y_{1i}, Y_{0i}) \perp D_j, \forall i \neq j$.
- Com interferência espacial, o resultado potencial de i depende do tratamento do vizinho j:

$$(Y_{1i}, Y_{0i}) \not\perp D_j, \text{ para algum } i \neq j$$

- A notação de resultados potenciais precisa ser expandida para $Y_i(D_i, \mathbf{D}_{-i})$, onde $\mathbf{D}_{-i}$ é o vetor de tratamento de todas as outras unidades.

Interferência

Notação Expandida de Resultados Potenciais

Considerando uma unidade i e seu vizinho j:

- $Y_i(0,0)$: Resultado de i quando nem i nem j são tratados (*Controle Puro*).
- $Y_i(0,1)$: Resultado de i quando i não é tratado, mas seu vizinho j é (*Controle Contaminado*).
- $Y_i(1,0)$: Resultado de i quando i é tratado, mas seu vizinho j não é.
- $Y_i(1,1)$: Resultado de i quando tanto i quanto j são tratados.

A existência de autocorrelação espacial torna a possível violação do SUTVA um caso relevante, não um caso especial ou exceção.

RCTs e Interferência

Em um **Randomized Controlled Trial** (RCT), a aleatorização completa e o SUTVA garantem a eliminação do viés de seleção.

$$\tau_{ATE} = E[Y|D=1] - E[Y|D=0]$$

Porém, com interferência espacial:

- O grupo de controle não é mais uma boa aproximação de $Y(0)$. O resultado observado para os não tratados é, na verdade, uma mistura de unidades não afetadas e unidades "contaminadas" pelo tratamento em seus vizinhos.
- A estimativa simples se torna enviesada:

$$\tau_{ATE} = E[Y|D=1] - E[Y|D=0] + \text{bias}$$

RCTs e Interferência

Decomposição dos Efeitos (Hudgens & Halloran, 2008)

É necessário definir múltiplos estimandos causais:

- **Efeito Direto (CE^D):** Efeito do tratamento em uma unidade, mantendo o tratamento dos vizinhos constante.
- **Efeito Indireto (CE^I):** Efeito em uma unidade não tratada de ter vizinhos tratados.
- **Efeito Total (CE^T):** Compara uma unidade tratada em um ambiente tratado com uma unidade não tratada em um ambiente não tratado.
- **Efeito Geral (CE^O):** Efeito médio de um programa de intervenção em relação a nenhum programa.

Uma Taxonomia das Abordagens Espaciais

Podemos classificar os métodos espaciais com base em como eles lidam com a "contaminação" dos spillovers.

1. Isolar e Remover

- **Lógica:** Excluir unidades "contaminadas" do grupo de controle.
- **Prós:** Simples de implementar.
- **Contras:** Perde informação, pode ser ineficiente, impossibilita a medição do spillover.

2. Modelar e Estimar

- **Lógica:** Tratar o spillover como um parâmetro de interesse a ser estimado.
- **Prós:** Fornece uma imagem mais completa dos efeitos do tratamento.
- **Contras:** Requer mais pressupostos sobre a forma funcional do spillover.

3. Re-balancear

- **Lógica:** Ajustar o pareamento ou a ponderação para levar em conta o contexto espacial.
- **Prós:** Corrige o viés no processo de seleção do tratamento.
- **Contras:** Pode não abordar diretamente o spillover no resultado.

Propensity Score Matching

Pareamento (Matching)

Na ausência de aleatorização, estratégias de identificação são necessárias. O **Matching** busca equilibrar os grupos de tratamento e controle com base em suas covariáveis.

Estimador de Pareamento de Vizinho (One-to-One)

1. Para cada unidade i, seleciona-se uma unidade $j(i)$ do grupo de tratamento oposto ($D_{j(i)} = 1D_i$) com valores de covariáveis similares ($X_{j(i)} \approx X_i$).
2. O estimador para o ATE é então construído usando as correspondências para tratados e não tratados:

$$\hat{\tau}_{ATE} = \frac{1}{n}\sum_{i=1}^{n} D_i(Y_i - Y_{j(i)}) - \frac{1}{n}\sum_{i=1}^{n}(1 - D_i)(Y_i - Y_{j(i)})$$

Pareamento (Matching)

Pareamento por Escore de Propensão (PSM)

Uma variação amplamente utilizada (Rosenbaum & Rubin, 1983) é o pareamento sobre o **escore de propensão**, $p(X)$, definido como:

$$p(X) = Pr(D = 1|X)$$

- **Vantagem:** Reduz a dimensionalidade da variável de pareamento, evitando a "maldição da dimensionalidade".
- **Na prática:** O escore $p(X)$ é estimado usando modelos logit ou probit.

Problema

A autocorrelação espacial nas covariáveis (X) pode enviesar a estimação do escore de propensão, $p(X) = Pr(D = 1|X)$, se o modelo para $p(X)$ (e.g., logit/probit) ignorar a estrutura espacial.

Pareamento (Matching)

Solução: Abordagem "Re-balancear"

Estimar o escore de propensão usando um modelo que incorpore a dependência espacial. Exemplo: **Modelo Probit Espacial**.

$$y^* = \rho W y^* + X\beta + \epsilon, \quad \epsilon \sim N(0, I_n)$$

Onde y^* é a variável latente para a decisão de tratamento ($D = 1$ se $y^* > 0$).

- O termo $\rho W y^*$ captura a dependência espacial na própria decisão de tratamento (e.g., um município é mais propenso a adotar uma política se seus vizinhos a adotarem).
- Usar o escore de propensão estimado por este modelo pode levar a um melhor balanceamento dos grupos de tratamento e controle.
- Pode-se substituir o termo $\rho W y^*$ por $WX\theta$, um modelo do tipo SLX, que captura o efeito das características dos vizinhos na decisão de tratamento e pode ser estimado por Probit clássico.

PSM: Fluxo de Trabalho Pós-Estimação do Escore

Após a regressão Probit/Logit gerar o escore de propensão $p(X)$ para cada unidade, o processo continua com as seguintes etapas:

1. **Realizar o Pareamento (Matching):**
   - **Objetivo:** Usar os escores para criar um grupo de controle que seja o mais parecido possível com o grupo de tratamento, encontrando para cada tratado um ou mais controles com escores similares.
   - **Técnicas Comuns:** Vizinho Mais Próximo (com/sem reposição), Pareamento por Caliper/Raio, Pareamento por Kernel.
2. **Verificar o Balanceamento das Covariáveis:**
   - **Objetivo:** Garantir que, *após* o pareamento, os grupos de tratamento e controle sejam estatisticamente indistinguíveis em relação às covariáveis observáveis (X).
   - **Métrica Principal:** Diferença de Médias Padronizada (SMD), que deve ser próxima de zero para todas as covariáveis.
3. **Estimar o Efeito do Tratamento (ATT):**
   - **Objetivo:** Com os grupos devidamente balanceados, calcular a diferença da média do resultado (Y) entre os tratados e os controles pareados.
   - $ATT = Média(Y_{tratados}) - Média(Y_{controles_pareados})$

Alternativa ao Matching: Ponderação pelo Inverso da Probabilidade (IPW)

Uma abordagem alternativa, também baseada no escore de propensão, é a **Inverse Probability Weighting (IPW)**.

Estimador IPW para o ATE

O método primeiro estima os escores de propensão, $\hat{p}(X_i)$, e depois os utiliza para ponderar os valores do resultado. O estimador para o ATE é dado por:

$$\hat{\tau}_{IPW} = \frac{1}{n}\sum_{i=1}^{n}\frac{D_i Y_i}{\hat{p}(X_i)} - \frac{1}{n}\sum_{i=1}^{n}\frac{(1-D_i)Y_i}{1-\hat{p}(X_i)}$$

- **Intuição:** Observações no grupo de tratamento com baixa probabilidade de serem tratadas (inesperadas) recebem um peso maior. Da mesma forma, observações no grupo de controle com alta probabilidade de serem tratadas (que *quase* foram tratadas) também recebem um peso maior.

Alternativa ao Matching: Ponderação para o ATT

Quando o interesse está no efeito do tratamento sobre aqueles que efetivamente o receberam (ATT), a ponderação é ajustada para que o grupo de controle se assemelhe ao grupo de tratamento.

Estimador IPW para o ATT

Apenas as observações do grupo de controle são ponderadas para criar um contrafactual para o grupo de tratamento. O estimador para o ATT é dado por:

$$\hat{\tau}_{ATT} = \frac{1}{n_1} \sum_{i=1}^{n} D_i Y_i - \frac{1}{n_1} \sum_{i=1}^{n} \frac{(1 - D_i)\hat{p}(X_i)}{1 - \hat{p}(X_i)} Y_i$$

Onde n_1 é o número de indivíduos no grupo de tratamento.

Alternativa ao Matching: Ponderação para o ATT

Intuição

- O resultado médio dos tratados é comparado com o resultado médio ponderado dos não tratados. O peso $\frac{\hat{p}(X_i)}{1-\hat{p}(X_i)}$ (as "chances" ou *odds* de tratamento) é aplicado aos controles.
- Indivíduos no grupo de controle que são muito parecidos com os do grupo de tratamento (ou seja, que tinham alta probabilidade de serem tratados, $\hat{p}(X_i) \to 1$) recebem um peso maior, tornando a média do grupo de controle um contrafactual mais preciso para o grupo de tratamento.

Matching e IPW

Desafio Espacial

- **Problema:** Tanto PSM quanto IPW podem de certa forma controlar parte da heterogeneidade espacial, mas não consideram a possibilidade de spillovers espaciais do tratamento, o que continua configurando uma violação do SUTVA por interferência espacial.

Regressão com Descontinuidade (RDD)

Regressão com Descontinuidade (RDD): Fundamentos

O RDD é uma abordagem quase-experimental importante quando a aleatorização não é viável e fatores não observáveis são uma preocupação.

Três Componentes-chave

O RDD, em sua forma mais simples, baseia-se em três elementos:

- **Score:** Uma variável contínua (X) que determina a elegibilidade.
- **Cutoff:** Um limiar claro (c) no score.
- **Regra de Atribuição Descontínua:** A probabilidade de tratamento muda abruptamente de zero para um no ponto de corte.

Regressão com Descontinuidade (RDD): Fundamentos

Lógica de Identificação no Sharp RDD

No RDD Sharp, a atribuição ao tratamento é perfeitamente determinada pelo score: $D = 1(X > c)$.

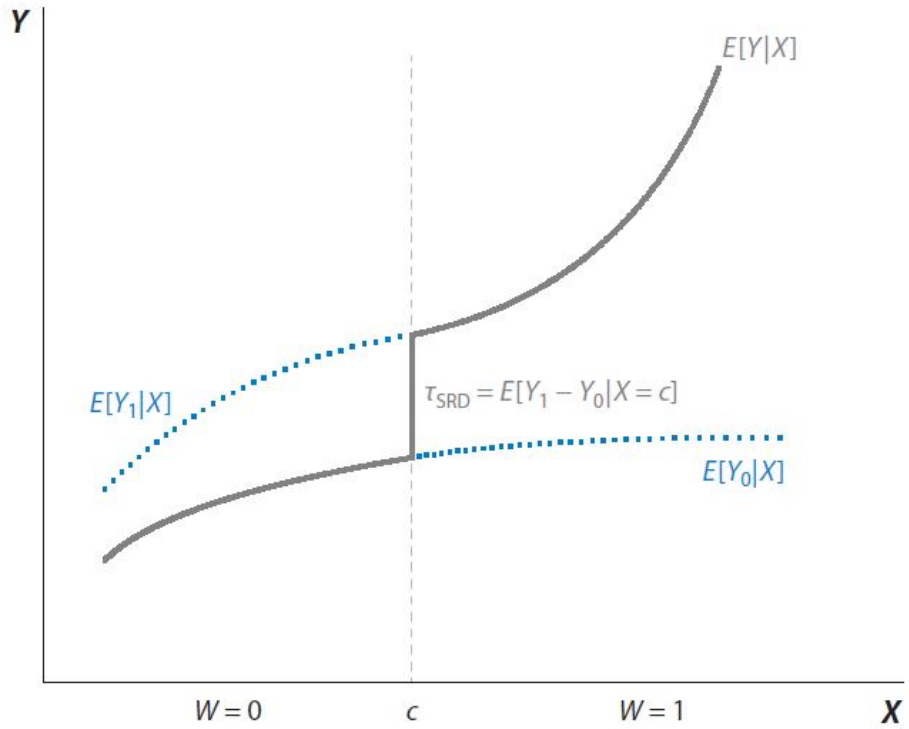
- **Pressuposto Central:** Unidades com scores logo abaixo do ponto de corte (c) podem servir como um grupo de controle válido para unidades com scores logo acima, pois são consideradas muito semelhantes em todas as outras características.
- **Efeito Causal:** O efeito médio do tratamento no ponto de corte é a diferença nos limites das esperanças condicionais do resultado (Y) de cada lado do cutoff:

$$\tau_{SRD} = E[Y_1 Y_0 | X = c] = \lim_{x \downarrow c} E[Y|X = x] - \lim_{x \uparrow c} E[Y|X = x]$$

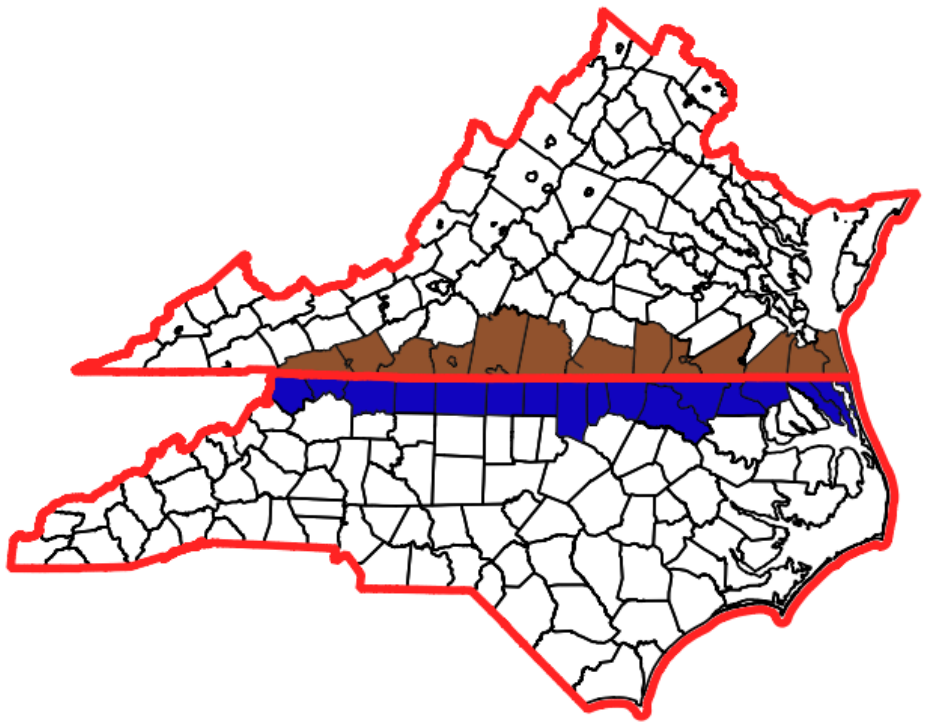
Regressão com Descontinuidade (RDD)

RDD Padrão (Sharp) O efeito é a descontinuidade na esperança condicional do resultado no ponto de corte c.

$$\tau_{SRD} = \lim_{x \downarrow c} E[Y|X = x] - \lim_{x \uparrow c} E[Y|X = x]$$



RDD Espacial (Geográfico) O "ponto de corte" é uma fronteira geográfica. Compara unidades imediatamente de cada lado da fronteira.



Regressão com Descontinuidade (RDD)

Lógica RDD Espacial

- Dada sua proximidade espacial, a única diferença significativa entre os efeitos observados do tratamento deveria ser o tratamento em si.

Problemas

- Spillovers através da fronteira podem *contaminar* as unidades de controle próximas, atenuando a descontinuidade e enviesando o efeito estimado.
- As diferentes regiões podem apresentar heterogeneidade espacial por regimes espaciais distintos.

RDD Espacial: O Trade-off de Validade

O RDD Espacial exemplifica um trade-off fundamental na inferência causal.

Validade Interna vs. Externa

- **Alta Validade Interna:** A comparação de unidades muito próximas da fronteira é plausível. Elas são provavelmente muito semelhantes em características não observáveis, isolando o efeito do tratamento.

RDD Espacial: O Trade-off de Validade

O RDD Espacial exemplifica um trade-off fundamental na inferência causal.

Validade Interna vs. Externa

- **Alta Validade Interna:** A comparação de unidades muito próximas da fronteira é plausível. Elas são provavelmente muito semelhantes em características não observáveis, isolando o efeito do tratamento.
- **Baixa Validade Externa:** O efeito estimado é, por construção, **altamente local**. O efeito causal na fronteira pode não ser representativo do efeito no interior da região tratada, onde as características das unidades (e, portanto, o efeito do tratamento) podem ser diferentes.

Implicação para Políticas Públicas

Um programa piloto avaliado como bem-sucedido em uma área de fronteira através de RDD pode não ter o mesmo sucesso quando implementado em toda a região. A extrapolação dos resultados de RDD requer pressupostos muito fortes.

Diferenças-em-Diferenças (Diff-in-Diff)

Diferenças-em-Diferenças (DID): Fundamentos

O método DID é uma das abordagens quase-experimentais mais populares, conhecido por sua simplicidade e utilidade em situações com variáveis de confusão não observáveis.

A Lógica da Dupla Diferença

O estimador calcula o efeito do tratamento comparando a mudança no resultado ao longo do tempo entre os grupos de tratamento e controle.

- **Primeira Diferença:** A mudança no resultado para o grupo de tratamento (Depois - Antes).
- **Segunda Diferença:** A mudança no resultado para o grupo de controle (Depois - Antes).

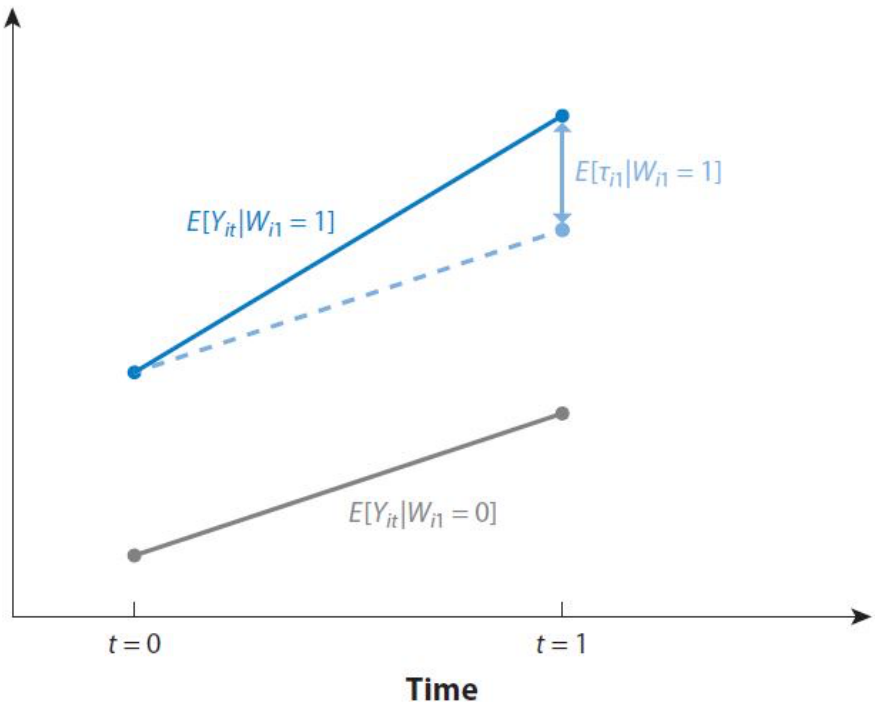
O efeito do tratamento (τ_{DID}) é a diferença entre essas duas mudanças. A segunda diferença serve como o contrafactual para a tendência temporal que o grupo tratado teria seguido sem a intervenção.

Diferenças-em-Diferenças (DID)

O modelo DID básico compara a mudança no resultado ao longo do tempo entre os grupos de tratamento e controle.

$$Y_{it} = \mu_i + \delta_t + \tau D_{it} + \epsilon_{it}$$

A identificação depende do **pressuposto de tendências paralelas**: na ausência do tratamento, os dois grupos teriam seguido a mesma trajetória.



Diferenças-em-Diferenças (DID)

Pressuposto: Tendências Paralelas (Common Trend Assumption)

A identificação do efeito causal depende crucialmente do pressuposto de que, na ausência do tratamento, a variação média do resultado para ambos os grupos teria sido a mesma.
Formalmente, para o resultado potencial sem tratamento (Y_0):

$$E[Y_{0i1}|D_{it} = 1] = E[Y_{0i1}|D_{it} = 0]$$

Graficamente, isso significa que as linhas de tendência dos dois grupos eram paralelas no período pré-tratamento e continuariam assim no período pós se não tivesse havido o tratamento.

Diferenças-em-Diferenças (DID)

Problema Espacial

Apesar do pressuposto de tendências paralelas controlar parte da heterogeneidade espacial, spillovers do grupo tratado para o grupo de controle **violam o SUTVA**. O grupo de controle *contaminado* não representa mais o contrafactual correto para o grupo tratado.

DID Espacial: A Abordagem "Modelar e Estimar"

Uma estratégia é expandir o modelo DID para estimar explicitamente os spillovers. O modelo **SLX-DID** (Delgado & Florax, 2015; Chagas et al., 2016) faz exatamente isso.

Modelo SLX-DID (forma simplificada)

Considere D_i um indicador para o grupo de tratamento e T_t um indicador para o período pós-tratamento.

$$Y_{it} = \beta_0 + \beta_1 D_i + \beta_2 T_t + \alpha_3 (D_i \times T_t) + \alpha_4 (WD_i \times T_t) + \cdots + \epsilon_{it}$$

- O termo de interação padrão, $D_i \times T_t$, captura o efeito do tratamento.
- O termo de interação espacial, $WD_i \times T_t$, captura o efeito de spillover.

Interpretação dos Coeficientes

- $\hat{\alpha}_3$: Estima o **Efeito Médio Direto do Tratamento (ADTE)**.
- $\hat{\alpha}_4$: Estima o **Efeito Médio Indireto do Tratamento (AITE)**, ou seja, o efeito de spillover sobre os vizinhos das unidades tratadas.

DID Espacial: A Abordagem "Modelar e Estimar"

Limitação Espacial

- O modelo **SLX-DID** não considera efeitos de feedback espacial como nos modelos autoregressivos espaciais (WY). O spillover espacial é apenas local, evitando assim problemas na estimação dos parâmetros e interpretação dos resultados.
- Além disso, assume-se que todas as unidades tratadas recebem o tratamento no mesmo período t. Fiorini et al. (2025) tenta resolver essa limitação com modelagem staggered DID (*unpublished*).

Método do Controle Sintético (SCM)

Método do Controle Sintético (SCM): Fundamentos

O SCM é uma alternativa popular a estudos de caso comparativos (como os anteriores), especialmente quando se lida com poucas unidades agregadas (e.g., estados, países), onde é difícil encontrar unidades de controle adequadas.

O Conceito Fundamental

A ideia central é que uma **combinação ponderada** de unidades não tratadas pode fornecer uma comparação muito melhor para a unidade tratada do que qualquer unidade de controle individualmente.

- O grupo de unidades de controle potenciais é chamado de **donor pool**.
- A média ponderada dessas unidades forma o **controle sintético**, que serve como o contrafactual.

Método do Controle Sintético (SCM): Fundamentos

Estimação e a Escolha dos Pesos

O efeito do tratamento no período t pós-intervenção é a diferença entre o resultado da unidade tratada e o resultado do seu controle sintético:

$$\hat{\tau}_{1t} = Y_{1t} - \sum_{j=2}^{J+1} w_j^* Y_{jt}$$

- Os pesos w_j^* são escolhidos para que o controle sintético replique a trajetória da unidade tratada no período **pré-tratamento**.
- Essa semelhança é otimizada com base em um conjunto de preditores do resultado e/ou valores passados da própria variável de resultado.
- Os pesos são restritos a serem não-negativos e somarem 1, garantindo que o controle sintético é uma combinação convexa das unidades do *donor pool*.

Método do Controle Sintético (SCM)

Problema Espacial

Se unidades no *donor pool* são afetadas por spillovers da unidade tratada, o controle sintético fica "contaminado", enviesando a estimativa. A solução ingênua ("Isolar e Remover") é descartar vizinhos do *donor pool*, o que pode ser problemático com poucas unidades e requer hipóteses sobre a delimitação espacial do spillover.

SCM Inclusivo: "Modelar e Estimar"

O método de Controle Sintético Inclusivo (Di Stefano & Mellace, 2020) é uma solução sofisticada que permite a presença de unidades afetadas por spillovers no donor pool.

Lógica

O método estima simultaneamente o efeito direto e o efeito de spillover resolvendo um sistema de equações.

1. Estima-se um SCM "enviesado"para a unidade tratada ($\hat{\theta}_t$), usando todo o donor pool.
2. Estima-se um SCM "enviesado"para a unidade afetada pelo spillover ($\hat{\gamma}_t$), usando as outras como controle.
3. Combina-se as informações para obter os efeitos não enviesados.

SCM Inclusivo: "Modelar e Estimar"

Solução (caso com 1 unidade afetada)

Efeito direto não enviesado:

$$\theta_t = \frac{\hat{\theta}_t + w_2^* \hat{\gamma}_t}{1 - w_2^* l_1^*}$$

Efeito indireto (spillover) não enviesado:

$$\gamma_t = \frac{\hat{\gamma}_t + l_1^* \hat{\theta}_t}{1 - w_2^* l_1^*}$$

Problema Espacial

Ainda requer hipóteses sobre a delimitação espacial do spillover.

Referências I

[1] Chagas, A. L., Azzoni, C. R. and Almeida, A. N. (2016), 'A spatial difference-indifferences analysis of the impact of sugarcane production on respiratory diseases', *Regional Science and Urban Economics* 59, 24–36.

[2] Delgado, M. S. and Florax, R. J. (2015), 'Difference-in-differences techniques for spatial data: Local autocorrelation and spatial interaction', *Economics Letters* 137, 123–126.

[3] Di Stefano, R. and Mellace, G. (2020), 'The inclusive synthetic control method', *Discussion Papers on Business and Economics*, University of Southern Denmark.

[4] Fiorini, M., Lee, W. and Pfeifer, G. (2025), 'A simple approach to staggered difference-in-differences in the presence of spillovers'. Available at: https://wooyong.github.io/data/papers/spillover.pdf

[5] Hudgens, M. G. and Halloran, M. E. (2008), 'Toward causal inference with interference', *Journal of the American Statistical Association* 103(482), 832–842.

Referências II

[6] Rosenbaum, P. R. and Rubin, D. B. (1983), 'The central role of the propensity score in observational studies for causal effects', *Biometrika* 70(1), 41–55.

[7] Serenini, R. (2025). *'Essays in Spatial Econometrics and Causal Inference'*. PhD Thesis - Sapienza University of Rome. Chapter 1.